
Aprendizagem Automática

FICHA N. 1

ENUNCIADO

Semestre de Inverno 2017/2018

Nome: Rui Filipe Guimarães Dos Santos

Número: A39286

1. No ficheiro `A39286_Q001_data.p`, encontram-se um conjunto de dados bi-dimensionais divididos em 3 classes (índices de 0 a 2). Há duas variáveis num dicionário: a chave `trueClass` contém os índices das classes dos dados, enquanto a chave `dados` contém os dados bi-dimensionais. Verificam-se as seguintes condições no conjunto de dados disponibilizado:

- | | |
|---|---|
| (a) A média dos dados é: $\begin{bmatrix} 0.41 \\ 0.55 \end{bmatrix}$ | (d) A distância entre as médias da classe 1 e da classe 0 é de 1.40 unidades. |
| (b) A percentagem de pontos da classe 2 é de 28.1% | (e) A matriz de covariância da classe 2 é: $\begin{bmatrix} 0.14 & 0.00 \\ 0.00 & 0.12 \end{bmatrix}$ |
| (c) A matriz de covariância dos dados é: $\begin{bmatrix} 0.14 & 0.00 \\ 0.00 & 0.12 \end{bmatrix}$ | (f) A média da classe 0 é: $\begin{bmatrix} -0.01 \\ -0.01 \end{bmatrix}$ |

2. Dado um conjunto de N pontos a d dimensões, pretende-se calcular a matriz de covariância dos dados. Para tal, assuma que:

- Já foi executado o comando: `import numpy as np`
- Os dados estão guardados numa variável X – array de dimensão $d \times N$.


As seguintes instruções em Python calculam a matriz de covariância dos dados (guardada na variável Cx):

- | | |
|--|--|
| (a) <code>Cx=np.cov(X, ddof=1)</code> | <code>Cx=Ctmp/(X.shape[1]-1)</code> |
| (b) <code>mx=np.mean(X, axis=1)</code>
<code>Xn=(X.T-mx).T</code>
<code>Ctmp=Xn*Xn</code>
<code>Cx=Ctmp/(X.shape[1]-1)</code> | (e) <code>mx=np.mean(X, axis=1)</code>
<code>Xn=X-mx[:, np.newaxis]</code>
<code>Ctmp=np.dot(Xn, Xn.T)</code>
<code>Cx=Ctmp/(X.shape[1]-1)</code> |
| (c) <code>Cx=np.cov(X.T, rowvar=False, ddof=0)</code> | (f) <code>mx=np.mean(X, axis=0)</code>
<code>mx=mx</code>
<code>Ctmp=np.dot(X, X.T)/(X.shape[1]-1)</code>
<code>Cx=Ctmp-np.dot(mx, mx.T)</code> |
| (d) <code>mx=np.mean(X, axis=0)</code>
<code>Xn=X-mx</code>
<code>Ctmp=np.dot(Xn, Xn.T)</code> | |

3. Considere uma variável aleatória 2D uniformemente distribuída na área a cinzento da figura. Considere que esta variável 2D foi obtida através de uma transformação linear de uma outra variável uniformemente distribuída no intervalo $x_1, x_2 \in [0, 1]$ (quadrado pequeno verde). A transformação consistiu em escalar a 1ª dimensão dos dados, x_1 , por um factor de 2, a segunda, x_2 por um factor de 3. Depois foi aplicada uma rotação contrária ao sentido dos ponteiros do relógio de -30 graus, seguido de uma translação. Em termos genéricos, esta transformação pode ser descrita segundo um produto matricial entre duas matrizes, R e Δ , de rotação e de escalamento dos dados, mais um vector b de translação.

$$\mathbf{y} = \mathbf{R}\Delta\mathbf{x} + \mathbf{b} = \mathbf{A}\tilde{\mathbf{x}} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{bmatrix} \begin{bmatrix} 1 \\ x_1 \\ x_2 \end{bmatrix}$$

Esta transformação também pode ser obtida através de um único produto matricial com uma matriz \mathbf{A} , representando os dados em coordenadas homogêneas.



As seguintes afirmações são verdadeiras (considere arredondamentos até à segunda casa decimal):

(a) A matriz de transformação é:

$$\mathbf{A} = \begin{bmatrix} -4.00 & 1.73 & 1.50 \\ 0.00 & -1.00 & 2.60 \end{bmatrix}$$

(b) O vector de translação é:

$$\mathbf{b} = \begin{bmatrix} -1.00 \\ 2.00 \end{bmatrix}$$

(c) A matriz de rotação é:

$$\mathbf{R} = \begin{bmatrix} 0.87 & -0.50 \\ 0.50 & 0.87 \end{bmatrix}$$

(d) A matriz de escalamento é:

$$\Delta = \begin{bmatrix} 2.00 & 0.00 \\ 0.00 & 2.00 \end{bmatrix}$$

4. Considere uma variável aleatória 2D, cuja a distribuição consiste numa soma de duas densidades Gaussianas 2d:

$$\mathcal{N}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1) \quad \text{com } \boldsymbol{\mu}_1 = \begin{bmatrix} -2 \\ 1 \end{bmatrix} \quad \text{e } \boldsymbol{\Sigma}_1 = \begin{bmatrix} 2.25 & -0.00 \\ -0.00 & 2.25 \end{bmatrix}$$

$$\mathcal{N}(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_2) \quad \text{com } \boldsymbol{\mu}_2 = \begin{bmatrix} 2 \\ -1 \end{bmatrix} \quad \text{e } \boldsymbol{\Sigma}_2 = \begin{bmatrix} 0.25 & 0.00 \\ 0.00 & 0.25 \end{bmatrix}$$

$$p(\mathbf{x}) = p_1 \mathcal{N}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1) + p_2 \mathcal{N}(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_2) \quad \text{com } p_1 = 0.50$$

Pretende-se gerar 1000 pontos com esta distribuição. Para tal assuma que já se executou o comando `import numpy as np` e `import scipy.linalg as la`. Assuma igualmente que já foram definidas as matrizes de covariância, os vetores de média, e as probabilidades a priori das Gaussianas (`np.array`s: matrizes de covariâncias 2×2 `S1` e `S2`, vetores de média 2×1 `m1` e `m2`. `float`s: probabilidades a priori `p1` e `p2`). Os seguintes comandos geram os pontos pretendidos (guardados na variável `X`):

```
(a) A1=la.sqrtm(S1)
    A2=la.sqrtm(S2)
    X1=np.dot(A1,np.random.randn(2,1000))+m1
    X2=np.dot(A2,np.random.randn(2,1000))+m2
    X=X1+X2
```

```
(b) A1=la.sqrtm(S1)
    A2=la.sqrtm(S2)
    X1=np.dot(A1,np.random.randn(2,1000))+m1
    X2=np.dot(A2,np.random.randn(2,1000))+m2
    X=np.hstack((X1,X2))
```

```
(c) A1=np.array([[0.00,1.50],[-1.50,0.00]])
    A2=np.array([[0.50,0.00],[0.00,0.50]])
    X1=A1*np.random.randn(2,1000*p1)+m1
    X2=A2*np.random.randn(2,1000*p1)+m2
    X=np.hstack((X1,X2))
```

```
(d) A1=la.sqrtm(S1)
    A2=la.sqrtm(S2)
    X1=A1*np.random.randn(2,1000)+m1
    X2=A2*np.random.randn(2,1000)+m2
    X=np.hstack((X1,X2))
```